

analytics

October 10, 2025

1 1. Introdução e Metadados

1.0.1 1.1. Contexto e Fontes de Dados

Os dados foram obtidos a partir da plataforma [Kaggle](#), em um dataset público compilado por Arian Azmoudeh.

- **Fonte Principal:** [New York City Airbnb Open Data](#).
- **Fonte Original:** Os dados são derivados da iniciativa [Inside Airbnb](#), que disponibiliza dados públicos sobre as listagens da plataforma em várias cidades do mundo.

1.0.2 Sobre o Airbnb

O Airbnb é uma plataforma que conecta pessoas que desejam alugar um espaço (como casas, apartamentos ou quartos) com viajantes em busca de acomodações temporárias. O serviço permite que anfitriões anunciem suas propriedades e que hóspedes reservem estadias, muitas vezes com preços mais acessíveis do que em hotéis tradicionais.

1.0.3 1.2. Sobre o Dataset e Estrutura

O dataset descreve a atividade de anúncios de acomodações na cidade de Nova York. As informações abrangem três áreas principais:

- **Anúncios (Listings):** Inclui descrições completas dos imóveis, localização geográfica (latitude e longitude), tipo de quarto, preço, regras da casa e informações sobre o anfitrião.
- **Avaliações (Reviews):** Contém dados sobre o número de avaliações, a data da última avaliação e a pontuação média das avaliações.
- **Disponibilidade (Calendar):** Informações sobre a disponibilidade do imóvel ao longo do ano (availability_365).

A escolha deste conjunto de dados se deve à sua riqueza de informações, que nos permite explorar diversas áreas do mercado de aluguel de curto prazo em Nova York. Dentre as várias opções analisadas, este dataset se destacou por apresentar um cenário completo e realista para um projeto de Ciência de Dados: ele combina um grande volume de registros com desafios claros de tratamento e limpeza.

Uma análise preliminar já nos permitiu identificar diversos pontos de melhoria, que encaramos como oportunidades para demonstrar um fluxo de trabalho robusto. Ao invés de um dataset perfeitamente limpo, a necessidade de prepará-lo nos permite agregar mais valor e confiança à análise final. Objetivo é ir além da simples visualização de dados, buscando insights sobre como diferentes variáveis se relacionam e influenciam o ecossistema do Airbnb.

1.0.4 1.3. Desafios de Qualidade e Limitações Iniciais

Entre as oportunidades de tratamento já identificadas, destacam-se: - **Tratamento de Valores Ausentes:** Percebemos uma quantidade significativa de dados faltantes em colunas estratégicas como “last review” e “reviews per month” que precisarão de alguma estratégia de tratamento para que não perdemos informações valiosas. - **Correção de Tipos de Dados:** Colunas cruciais para a análise, como “price” e “service fee”, estão com formato de texto por conta da utilização de caracteres especiais como “\$”. A conversão para um formato numérico será necessária para análises futuras. - **Agrupamento de Dados:** A coluna “house_rules”, mesmo com dados ausentes, pode ser transformada em uma variável binária para associar em análises envolvendo avaliações e no próprio preço.

Por fim, a [fonte original](#) nos traz algumas informações interessantes:

- O Airbnb torna anônimas algumas informações de localização de um anúncio. Isso significa que uma localização (com latitude e longitude) está num raio de 150m do endereço original. Assim, por exemplo, dois anúncios num mesmo edifício podem estar com latitudes e longitudes muito discrepantes.
- O nome do bairro em um anúncio é calculado a partir das suas coordenadas geográficas.

2 2. Análise Exploratória

A seguir, utilizaremos Python para auxiliar na análise dos dados brutos. Com a biblioteca [Pandas](#), podemos visualizar e alterar os dados utilizando **Dataframes** e **Series**. Uma **Series** é um array unidimensional, e um **Dataframe** é como uma tabela, em que cada coluna é uma **Series**.

Além dessas bibliotecas, também podemos usar a **seaborn** para desenhar gráficos com base nos dados das **Series** e **Dataframes**.

2.1 2.1 Importação das bibliotecas e carregamento do Dataset

```
[1]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from matplotlib.lines import Line2D
from matplotlib.ticker import MaxNLocator
import numpy as np
import folium
from folium.plugins import FastMarkerCluster
from IPython.display import display
import pycountry
import plotly.express as px
import geopandas as gpd
import folium
import matplotlib.pyplot as plt
import matplotlib.colors as mcolors
from branca.element import Template, MacroElement
from folium.plugins import HeatMap
```

```
[2]: df = pd.read_csv("./airbnb-dataset.csv", sep=",", encoding='utf8',
↳ low_memory=False)
```

2.2 Head do Dataset

A tabela apresentada mostra as cinco primeiras entradas do nosso conjunto de dados, o que nos permite uma verificação inicial das colunas disponíveis e dos tipos de dados que elas contêm.

```
[3]: df.head(5)
```

```
[3]:      id                                     NAME      host id \
0  1001254          Clean & quiet apt home by the park  80014485718
1  1002102                                Skylit Midtown Castle  52335172823
2  1002403          THE VILLAGE OF HARLEM...NEW YORK !  78829239556
3  1002755                                             NaN  85098326012
4  1003689  Entire Apt: Spacious Studio/Loft by central park  92037596077
```

```
      host_identity_verified host name neighbourhood group neighbourhood \
0          unconfirmed      Madaline          Brooklyn      Kensington
1          verified        Jenna          Manhattan      Midtown
2           NaN          Elise          Manhattan      Harlem
3      unconfirmed        Garry          Brooklyn  Clinton Hill
4          verified      Lyndon          Manhattan      East Harlem
```

```
      lat      long      country  ... service fee minimum nights \
0  40.64749 -73.97237  United States  ...      $193          10.0
1  40.75362 -73.98377  United States  ...      $28          30.0
2  40.80902 -73.94190  United States  ...     $124           3.0
3  40.68514 -73.95976  United States  ...      $74          30.0
4  40.79851 -73.94399  United States  ...      $41          10.0
```

```
      number of reviews last review  reviews per month review rate number \
0           9.0  10/19/2021           0.21           4.0
1          45.0   5/21/2022           0.38           4.0
2           0.0          NaN           NaN           5.0
3         270.0   7/5/2019           4.64           4.0
4           9.0  11/19/2018           0.10           3.0
```

```
      calculated host listings count  availability 365 \
0           6.0           286.0
1           2.0           228.0
2           1.0           352.0
3           1.0           322.0
4           1.0           289.0
```

```
      house_rules license
0  Clean up and treat the home the way you'd like...  NaN
```

1	Pet friendly but please confirm with me if the...	NaN
2	I encourage you to use my kitchen, cooking and...	NaN
3		NaN NaN
4	Please no smoking in the house, porch or on th...	NaN

[5 rows x 26 columns]

2.3 2.3 Dimensões do Dataset

Após a primeira visualização, o próximo passo é verificar as dimensões do nosso conjunto de dados. A “dimensão” de um dataset refere-se à sua estrutura em termos de quantidade de linhas e colunas.

Conforme o resultado abaixo, nosso dataset é composto por 102.599 linhas e 26 colunas, o que nos dá uma noção do volume de dados que iremos analisar.

```
[4]: linhas, colunas = df.shape

print(f"Número de tuplas: {linhas}")
print(f"Número de colunas: {colunas}")
```

Número de tuplas: 102599

Número de colunas: 26

2.4 2.4 Identificação das Colunas e Tipos de Dados

Agora que conhecemos as dimensões gerais do nosso dataset, o próximo passo é nos aprofundarmos nessas 26 colunas. Precisamos identificar o nome de cada uma das variáveis que temos à disposição para entender com quais informações estamos trabalhando.

O comando a seguir listará todas as colunas, dando uma visão dos atributos disponíveis para cada imóvel.

```
[5]: df.columns
```

```
[5]: Index(['id', 'NAME', 'host id', 'host_identity_verified', 'host name',
          'neighbourhood group', 'neighbourhood', 'lat', 'long', 'country',
          'country code', 'instant_bookable', 'cancellation_policy', 'room type',
          'Construction year', 'price', 'service fee', 'minimum nights',
          'number of reviews', 'last review', 'reviews per month',
          'review rate number', 'calculated host listings count',
          'availability 365', 'house_rules', 'license'],
          dtype='object')
```

Com os nomes das colunas já identificados, vamos entender como os dados de cada variável estão sendo interpretados. Verificar os tipos de dados (dtypes) é um passo importante para garantir a integridade da análise e planejar a etapa de limpeza.

O resultado a seguir nos revela alguns pontos de atenção imediatos, colunas que deveriam ser numéricas, como `price` e `service fee`, ou de data, como `last review`, estão classificadas como object (texto). Isso indica que elas contêm caracteres não numéricos e precisarão de tratamento antes de serem usadas em cálculos ou análises.

```
[6]: df.dtypes
```

```
[6]: id                int64
     NAME              object
     host id           int64
     host_identity_verified object
     host name         object
     neighbourhood group object
     neighbourhood     object
     lat              float64
     long             float64
     country           object
     country code      object
     instant_bookable  object
     cancellation_policy object
     room type         object
     Construction year float64
     price             object
     service fee       object
     minimum nights    float64
     number of reviews float64
     last review       object
     reviews per month float64
     review rate number float64
     calculated host listings count float64
     availability 365   float64
     house_rules       object
     license           object
     dtype: object
```

É importante ressaltar que o Pandas usa a nomenclatura `object` tanto para strings quanto para tipos mistos. No caso, os valores das colunas com `object` são mistos.

2.5 2.5 Qualidade dos Dados

2.5.1 2.5.1 Análise de Valores Ausentes (Nulos/NaN)

Dados não nulos Enquanto o passo anterior nos mostrou apenas os tipos de dados, a análise a seguir também revelará a quantidade de valores não nulos em cada coluna, nos dando um panorama sobre a presença de dados ausentes.

Este diagnóstico serve para identificar lacunas que precisam ser tratadas antes de qualquer análise mais profunda. Podemos observar que colunas como `license`, `house_rules`, `reviews per month` e `last review` possuem uma quantidade significativa de valores faltantes. A coluna `license`, em particular, está quase que inteiramente vazia.

Identificar esses dados ausentes é um passo importante para definirmos uma estratégia de limpeza.

```
[7]: df.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 102599 entries, 0 to 102598
Data columns (total 26 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   id                                    102599 non-null  int64
1   NAME                                102349 non-null  object
2   host id                             102599 non-null  int64
3   host_identity_verified              102310 non-null  object
4   host name                           102193 non-null  object
5   neighbourhood group                 102570 non-null  object
6   neighbourhood                       102583 non-null  object
7   lat                                 102591 non-null  float64
8   long                                102591 non-null  float64
9   country                             102067 non-null  object
10  country code                        102468 non-null  object
11  instant_bookable                    102494 non-null  object
12  cancellation_policy                 102523 non-null  object
13  room type                           102599 non-null  object
14  Construction year                   102385 non-null  float64
15  price                               102352 non-null  object
16  service fee                         102326 non-null  object
17  minimum nights                      102190 non-null  float64
18  number of reviews                   102416 non-null  float64
19  last review                         86706 non-null  object
20  reviews per month                   86720 non-null  float64
21  review rate number                  102273 non-null  float64
22  calculated host listings count      102280 non-null  float64
23  availability 365                    102151 non-null  float64
24  house_rules                         50468 non-null  object
25  license                             2 non-null      object
dtypes: float64(9), int64(2), object(15)
memory usage: 20.4+ MB

```

Dados nulos No passo anterior, o método `info()` nos deu um bom indicativo da presença de dados ausentes. Para abordar esse problema, vamos calcular a soma exata de valores nulos para cada coluna do dataset.

```
[8]: df.isnull().sum()
```

```

[8]: id                0
     NAME             250
     host id           0
     host_identity_verified  289
     host name         406
     neighbourhood group    29
     neighbourhood       16

```

lat	8
long	8
country	532
country code	131
instant_bookable	105
cancellation_policy	76
room type	0
Construction year	214
price	247
service fee	273
minimum nights	409
number of reviews	183
last review	15893
reviews per month	15879
review rate number	326
calculated host listings count	319
availability 365	448
house_rules	52131
license	102597
dtype: int64	

Tuplas com pelo menos um valor ausente (Nulos/NaN)

```
[9]: number_of_rows_with_null_nan_values = len(df.isnull().any(axis=1))
print(f"Número de registros com pelo menos um valor nulo ou nan:␣
↪{number_of_rows_with_null_nan_values}")
```

Número de registros com pelo menos um valor nulo ou nan: 102599

Quando dizemos que um valor pode ser nulo ou NaN, estamos nos baseando na própria documentação do pandas. Nela está explicado que uma coluna do tipo object pode conter valores ausentes representados tanto por NaN, do NumPy, quanto por None, do Python. Apesar dessa diferença, o pandas interpreta os dois de forma equivalente e considera ambos como nulos ao usar funções como `isna()` ou `isnull()`.

Porcentagem de nulos por coluna Embora a contagem de nulos nos dê os números exatos, uma representação visual é muito mais eficaz para compreender a magnitude do problema e comunicar nossos achados. Para isso, vamos agora plotar um gráfico de barras que exibirá o *percentual de dados ausentes* para cada coluna.

```
[10]: null_perc = (df.isnull().sum() / len(df) * 100).sort_values(ascending=False)

colors = ['#d9534f' if v > 50 else '#f0ad4e' if v > 10 else '#5bc0de' for v in␣
↪null_perc.values]

sns.set_theme(style="whitegrid")
plt.figure(figsize=(16, 8))
```

```


ax = sns.barplot(x=null_perc.values, y=null_perc.index, hue=null_perc.index,
                palette=colors, legend=False)

plt.suptitle("Porcentagem de Valores Ausentes por Coluna", fontsize=18, y=0.96)
ax.set_title("Vermelho: >50% | Laranja: 10-50% | Azul: <10%", fontsize=10)
ax.set_xlabel("Porcentagem (%)")
ax.set_xlim(0, 100)

for p in ax.patches:
    w = p.get_width()
    ax.text(w + 1, p.get_y() + p.get_height()/2, f'{w:.3f}%', va='center')

ax.axvline(50, color='darkred', linestyle='--', alpha=0.7)
plt.tight_layout(rect=[0, 0, 1, 0.95])
plt.show()

```



Observemos algumas colunas com dados interessantes:

- **license:** A coluna license tem apenas 2 registros que não vem com valor nulo. Todos os outros são nulos. O que torna esse campo tão importante? Por que a esmagadora maioria não precisa de uma licença? E por que especificamente 2 anúncios tem? Existe algo que torna esses anúncios diferentes dos demais?
- **house_rules:** A coluna house_rules tem quase metade dos seus valores como nulos. Ou seja: metade dos aluguéis não vêm com regras explícitas.
- **last_review:** mais de 80% dos anúncios teve pelo menos uma avaliação.
- **country** e **country code:** embora saibamos que os dados se referem sempre à cidade de Nova York, ainda assim existem registros que não indicam que o país do anúncio é os Estados Unidos.
- **id** e **name:** nenhum dos registros não tem identificador. No entanto, ainda existem registros que não tem nome (embora sejam de quantidade quase desprezível). O que levanta a pergunta:

o site do airbnb permitiu anúncios sem nome? Ou houve falha no momento da extração dos dados?


- **long, lat, neighbourhood e neighbourhood group:** apenas 8 registros não tem latitude e longitude, mas o dobro de registros não pertence a nenhum bairro, e quase o triplo não pertence a nenhum grupo de bairro. Isso é importante porque **neighbourhood** e **neighbourhood group** são gerados a partir dos valores de latitude e longitude. Se apenas 8 registros não têm esses valores, por que 16 não tem bairro definido e 29 não tem um grupo de bairro definido?
- **price:** pouquíssimos registros não tem um preço definido. Como alguém faria um aluguel sem saber por quanto seria?

Distribuição de dados ausentes O gráfico de barras nos deu um resumo da quantidade de dados ausentes em cada coluna. Agora, para entender a distribuição e os padrões desses valores nulos ao longo do dataset, o mapa de calor (heatmap) a seguir é muito bom para essa tarefa. Ele nos oferece uma representação visual de todo o conjunto de dados, onde as linhas mais claras indicam um dado faltante.

Essa visualização é valiosa porque nos ajuda a identificar se a ausência de dados é aleatória ou se há correlações. Por exemplo, podemos verificar se os dados faltantes em uma coluna coincidem com os de outra, o que pode revelar problemas estruturais nos registros e guiar uma estratégia de limpeza.

```
[11]: sns.heatmap(df.isnull())
```

```
[11]: <Axes: >
```



2.5.2 2.5.2 Identificação de Registros Duplicados

Total de tuplas com id's duplicados Após investigarmos a fundo os dados ausentes, o próximo passo na etapa de limpeza é verificar a existência de registros duplicados. Entradas repetidas podem contaminar a análise, distorcendo métricas, estatísticas e os resultados de qualquer modelo que venha a ser construído.

O código a seguir fará uma varredura em todo o conjunto de dados para identificar e contar quantas linhas são cópias exatas de outras. Este é um diagnóstico importante para garantir que cada registro em nossa análise seja único e represente uma observação distinta.

```
[12]: total = len(df)
      dups = df.duplicated().sum()

      print(f"Total de linhas: {total}")
      print(f"Total de duplicadas: {dups}")
```

Total de linhas: 102599
Total de duplicadas: 541

Amostra das tuplas duplicadas Após confirmarmos a existência de registros duplicados, inspecionaremos uma amostra deles antes de tomar qualquer ação. Queremos entender a natureza dessas duplicatas para garantir que estamos tratando o problema corretamente.

O código a seguir agrupa as linhas que são idênticas em todas as colunas, exceto pelo id, e nos mostra quais são elas. A tabela resultante exibirá os registros repetidos, a quantidade de vezes que eles aparecem (ocorrências), e a lista de ids diferentes associados a cada um.

Amostra das linhas duplicadas, indicando a quantidade de ocorrências, os respectivos IDs duplicados e as posições correspondentes no dataset original:

```
[13]: resumo = (
      df.groupby([c for c in df.columns if c != "id"], dropna=False)
        .agg(ids=("id", list),
              ocorrencias=("id", "size"),
              posicoes=("id", lambda s: list(s.index)))
        .reset_index()
        .query("ocorrencias > 1")
        .sort_values("ocorrencias", ascending=False)
    )

    resumo = resumo[["ids", "NAME", "ocorrencias", "posicoes"] +
                   [c for c in resumo.columns if c not in
                     ["ids", "NAME", "ocorrencias", "posicoes"]]]
    resumo
```

```
[13]:          ids \
109      [20405844, 20405844]
184      [35537207, 35537207]
304      [35596856, 35596856]
558      [35598513, 35598513]
712      [6027818, 6027818]
...
101038 [20347853, 20347853]
101054 [20331284, 20331284]
101064 [20330731, 20330731]
101070 [20329075, 20329075]
101175 [6064822, 6064822]
```

	NAME	ocorrencias	\
109	"In the Clouds" Brooklyn Heights Studio	2	
184	# 2 One Lexury Bedroom close to JFK AIRPORT	2	
304	#510 Furnished studio in the heart of Manhattan	2	
558	****THE SUITE LIFE DUPLEX****	2	
712	*ENCHANTMENT* Upper East Side 2 bedroom- Sunny!	2	
...	...	...	
101038	Sunnyside -Locals' favorite neighbor for liv...	2	
101054	2 Bedroom Apartment - Minutes from Times Squ...	2	
101064	Manhattan's Retreat - Blocks from Times Square!	2	
101070	Secret Hideaway - Blocks from Times Square!	2	
101175	Private Rm/Women's Safe Art Home	2	

	posicoes	host id	host_identity_verified	host name	\
109	[35134, 102464]	7007990163	verified	Jenna	
184	[62531, 102113]	12648350548	verified	Gelen	
304	[62639, 102221]	22417870465	verified	Best Inns USA	
558	[62642, 102224]	2578777349	verified	Kila	
712	[9101, 102477]	73401481508	unconfirmed	Juliana	
...	...	...	...	...	
101038	[35029, 102359]	150519910	verified	Haruhisa	
101054	[34999, 102329]	68697232838	unconfirmed	Louis	
101064	[34998, 102328]	46042736282	verified	Louis	
101070	[34995, 102325]	81558036123	verified	Louis	
101175	[9168, 102544]	27646270360	unconfirmed	Sarah	

	neighbourhood group	neighbourhood	lat	...	service fee	\
109	Brooklyn	Brooklyn Heights	40.695030	...	\$61	
184	Queens	Springfield Gardens	40.664089	...	\$189	
304	Manhattan	Gramercy	40.733810	...	\$128	
558	Brooklyn	Bedford-Stuyvesant	40.689760	...	\$189	
712	Manhattan	Upper East Side	40.762440	...	\$108	
...	...	...	...	...	...	
101038	Queens	Sunnyside	40.739980	...	\$199	
101054	Manhattan	Hell's Kitchen	40.756110	...	\$154	
101064	Manhattan	Hell's Kitchen	40.756550	...	\$159	
101070	Manhattan	Hell's Kitchen	40.756580	...	\$13	
101175	Brooklyn	Bedford-Stuyvesant	40.684110	...	\$124	

	minimum nights	number of reviews	last review	reviews per month	\
109	8.0	1.0	9/27/2018	0.10	
184	3.0	9.0	11/10/2021	0.80	
304	30.0	1.0	11/6/2021	0.25	
558	7.0	68.0	11/5/2021	1.01	
712	30.0	9.0	9/30/2018	0.20	
...	...	...	...	...	
101038	29.0	1.0	10/11/2018	0.11	

101054	1.0	41.0	7/1/2019	4.73
101064	1.0	44.0	7/4/2019	4.07
101070	1.0	41.0	6/18/2019	3.80
101175	1.0	4.0	10/7/2015	0.08

	review	rate	number	calculated host listings count	availability	365 \
109			3.0	1.0		207.0
184			5.0	5.0		365.0
304			5.0	20.0		124.0
558			2.0	2.0		175.0
712			5.0	34.0		411.0
...			...	...		...
101038			3.0	5.0		0.0
101054			5.0	3.0		30.0
101064			5.0	3.0		36.0
101070			5.0	3.0		64.0
101175			3.0	3.0		38.0

	house_rules	license
109	No Smoking and No Pets	NaN
184	NaN	NaN
304	NaN	NaN
558	NaN	NaN
712	Please treat it as it were your own home and b...	NaN
...	...	...
101038	NO PETS. NO SMOKING. NO PARTIES. No recreat...	NaN
101054	#NAME?	NaN
101064	We don't allow smoking, drug use, excessive pa...	NaN
101070	Please be respectful and courteous of other ho...	NaN
101175	No Smoking No Pets	NaN

[541 rows x 28 columns]

Proporção entre duplicados e únicos: Agora que identificamos o número absoluto de duplicatas e inspecionamos uma amostra, o próximo passo de diagnóstico é colocar esse número em perspectiva. Esse gráfico vai mostrar qual é o real impacto desses registros no volume total de dados.

```
[14]: total = len(df)
dups = df.duplicated().sum()
stats = pd.DataFrame({
    "tipo": ["Duplicados", "Únicos"],
    "porcentagem": pd.Series([dups, total - dups]) / total * 100
})

sns.set_theme(style="whitegrid")
plt.figure(figsize=(6,4))
```


```

ax = sns.barplot(
    data=stats,
    x="tipo", y="porcentagem",
    hue="tipo", palette=["#d9534f", "#5bc0de"],
    legend=False
)

for p in ax.patches:
    h = p.get_height()
    ax.text(p.get_x()+p.get_width()/2, h+1, f"{h:.2f}%", ha="center")

ax.set_title("Porcentagem de Duplicados vs Únicos")
ax.set_ylabel("Porcentagem (%)")
plt.ylim(0, 110)
plt.tight_layout()
plt.show()

```



Distribuição das duplicadas: Já estabelecemos a quantidade e a proporção dos registros duplicados. Uma pergunta que podemos fazer nesta fase é sobre a sua distribuição. Essas linhas repetidas estão concentradas em alguma parte específica do dataset ou estão espalhadas de forma aleatória?

Para investigar isso, o código a seguir irá gerar um gráfico de distribuição. Cada ponto no gráfico representará uma linha do nosso dataset, colorida de acordo com seu status: azul para registros

únicos e vermelho para duplicados.


```
[15]: alpha_unico, size_unico = 0.5, 1
alpha_dup, size_dup = 1, 1

plot_df = pd.DataFrame({
    "Índice": df.index,
    "Duplicado": df.duplicated(keep=False).map({True: "Duplicado", False: "Único"})
})

fig, ax = plt.subplots(figsize=(12, 3))
sns.stripplot(data=plot_df[plot_df.
    ↳Duplicado=="Único"], x="Índice", y=[""]*plot_df.Duplicado.eq("Único").sum(),
              color="steelblue", alpha=alpha_unico, size=size_unico, ax=ax)
sns.stripplot(data=plot_df[plot_df.
    ↳Duplicado=="Duplicado"], x="Índice", y=[""]*plot_df.Duplicado.eq("Duplicado").
    ↳sum(),
              color="red", alpha=alpha_dup, size=size_dup, ax=ax)

legend_elements=[Line2D([0], [0], marker='o', color='w', label='Único', markerfacecolor='steelblue',
    ↳
    ↳Line2D([0], [0], marker='o', color='w', label='Duplicado', markerfacecolor='red', markersize=6)]
ax.legend(handles=legend_elements, title="Status", loc="upper right")

plt.title("Distribuição dos duplicados (linhas inteiras)")
plt.xlabel("Índice"); plt.ylabel("")
plt.tight_layout(); plt.show()
```



2.5.3 2.5.3 Resumo Estatístico Descritivo das Colunas

Após a verificação estrutural de dados ausentes e duplicados, a próxima etapa da nossa análise é entender a distribuição e as propriedades estatísticas das nossas colunas numéricas. Isso é importante para identificar a dispersão dos dados, a presença de outliers e possíveis erros de registro que não são aparentes em uma simples visualização de tabela.

```
[16]: df.drop(columns=["id", "host id"]).describe()
```

```
[16]:
```

	lat	long	Construction year	minimum nights \
count	102591.000000	102591.000000	102385.000000	102190.000000
mean	40.728094	-73.949644	2012.487464	8.135845
std	0.055857	0.049521	5.765556	30.553781
min	40.499790	-74.249840	2003.000000	-1223.000000
25%	40.688740	-73.982580	2007.000000	2.000000
50%	40.722290	-73.954440	2012.000000	3.000000
75%	40.762760	-73.932350	2017.000000	5.000000
max	40.916970	-73.705220	2022.000000	5645.000000

	number of reviews	reviews per month	review rate number \
count	102416.000000	86720.000000	102273.000000
mean	27.483743	1.374022	3.279106
std	49.508954	1.746621	1.284657
min	0.000000	0.010000	1.000000
25%	1.000000	0.220000	2.000000
50%	7.000000	0.740000	3.000000
75%	30.000000	2.000000	4.000000
max	1024.000000	90.000000	5.000000

	calculated host listings count	availability 365
count	102280.000000	102151.000000
mean	7.936605	141.133254
std	32.218780	135.435024
min	1.000000	-10.000000
25%	1.000000	3.000000
50%	1.000000	96.000000
75%	2.000000	269.000000
max	332.000000	3677.000000

O comando `'df.describe()'` é uma ferramenta de diagnóstico do pandas que gera um resumo estatístico de todas as colunas de um DataFrame, tanto as numéricas quanto as textuais. Ao aplicá-lo em nosso conjunto de dados, obtivemos um panorama da qualidade dos dados, o que nos permitiu identificar pontos candidatos para a etapa de limpeza (camada Silver).

Constatamos que colunas essenciais como **price** e **service fee** estão formatadas incorretamente como texto, e não como números. Além disso, a análise expôs erros claros, como um valor mínimo impossível de -10 para a coluna **availability_365**, e outliers em **minimum_nights**. Por fim, o resumo quantificou a alta incidência de dados ausentes em colunas como **last_review** e **house_rules**, fornecendo esses campos como indicados para a etapa de tratamento do dataset.

2.5.4 2.5.4 Problemas de Formato

Nossa análise, especialmente o resumo estatístico, revelou um ponto crítico de colunas que deveriam ser numéricas, como **price** e **service fee**, não apareceram nos cálculos. Isso acontece porque elas foram interpretadas como texto (object).

Para corrigir esse problema, precisamos primeiro entender a causa. O código a seguir irá isolar essas duas colunas e exibir seus primeiros valores, além de confirmar seus tipos de dados. Essa inspeção

visual nos permitirá identificar quais caracteres não numéricos estão impedindo a conversão e precisam ser removidos.

```
[17]: primeiros_valores = df[['price', 'service fee']].head()

print(primeiros_valores)

print("\nTipos de dados das colunas:")
print(df[['price', 'service fee']].dtypes)
```

```
   price service fee
0  $966         $193
1  $142          $28
2  $620         $124
3  $368          $74
4  $204          $41
```

```
Tipos de dados das colunas:
price          object
service fee    object
dtype: object
```

2.5.5 2.5.5 Valores Inconsistentes (Outliers negativos)

Durante a análise do resumo estatístico, levantamos a suspeita sobre valores inconsistentes, como um mínimo negativo para a coluna `availability_365`. Valores negativos em campos que não podem ser negativos são erros de dados que precisam ser tratados.

Para investigar isso, o código a seguir fará uma varredura em todas as colunas numéricas para contar a ocorrência de valores negativos.

```
[18]: df_numeric = df.select_dtypes(include=np.number)
contagem_negativos = (df_numeric < 0).sum()
colunas_e_contagem = contagem_negativos[contagem_negativos > 0]

print("Contagem de valores negativos por coluna:")
print(colunas_e_contagem)
```

```
Contagem de valores negativos por coluna:
long          102591
minimum nights      13
availability_365    432
dtype: int64
```

2.5.6 Conclusão da Análise Exploratória e Próximos Passos

A fase de Análise Exploratória de Dados foi concluída, nos fornecendo um panorama sobre a estrutura, a qualidade e as características do nosso conjunto de dados. Através desta investigação, embora rico em informações, o dataset possui diversas inconsistências que precisam ser tratadas antes de qualquer análise aprofundada.

Os principais problemas identificados foram:

- Dados Ausentes: Uma alta porcentagem de valores nulos em colunas como `license` e `house_rules`.
- Dados Duplicados: A presença de 541 registros completamente idênticos.
- Problemas de Formato: Colunas financeiras cruciais (`price`, `service fee`) formatadas incorretamente como texto.
- Valores Inconsistentes: A existência de valores ilógicos, como `minimum nights` e `availability_365` negativos, além de outliers extremos.

A conclusão desta etapa é que o dataset em seu estado bruto não é adequado para fazer uma análise confiável. Portanto, o próximo passo será focado na Limpeza, onde iremos executar um plano para corrigir cada um dos problemas levantados.